

Wybrane zagadnienia uczenia maszynowego

Raport

Przewidywanie składów All-NBA i All-Rookie

Autor:

Artsiom Kruk

nr albumu: 157873

`artsiom.kruk@student.put.poznan.pl`

Poznań, 2026

Spis treści

1	Wprowadzenie	2
2	Cel i zakres projektu	2
3	Opis problemu	2
4	Dane i przygotowanie zbioru	3
5	Inżynieria cech	5
5.1	Cechy podstawowe	5
5.2	Cechy sumaryczne	5
5.3	Cechy z poprzedniego sezonu	6
5.4	Cechy drużynowe i względne względem drużyny	6
5.5	Cechy przygotowane do eksperymentów	6
6	Metodyka eksperymentów	6
6.1	Dobór modeli pierwszego etapu	6
6.2	Analiza drugiego etapu	9
6.3	Porównanie zestawów cech	10
6.4	Zakres danych użytych w projekcie	12
6.5	Architektura finalnego modelu	12
7	Wynik końcowy	13
8	Analiza błędów i ograniczenia	14
9	Instrukcja uruchomienia	14
10	Wnioski	15

1 Wprowadzenie

Projekt dotyczy przewidywania składów nagród NBA na podstawie danych statystycznych z sezonu regularnego. Rozważane są dwie grupy nagród: All-NBA, gdzie należy przewidzieć trzy pięcioosobowe drużyny, oraz All-Rookie, gdzie należy przewidzieć dwie pięcioosobowe drużyny debiutantów.

Zadanie potraktowano jako problem klasyfikacyjno-porządkujący. Model nie powinien zwracać jedynie informacji, czy zawodnik powinien zostać wybrany, ale także uporządkowaną listę kandydatów oraz przypisanie ich do odpowiednich drużyn. Z tego powodu problem jest trudniejszy niż standardowa klasyfikacja binarna.

2 Cel i zakres projektu

Celem projektu było przygotowanie kompletnego potoku uczenia maszynowego, który:

- pobiera i przetwarza dane statystyczne zawodników NBA,
- łączy dane z etykietami historycznych nagród,
- buduje cechy opisujące formę zawodnika, kontekst drużyny i historię kariery,
- trenuje modele dla All-NBA oraz All-Rookie,
- generuje ostateczny plik z przewidywaniami w formacie JSON,
- umożliwia ocenę wyników przewidywania według punktacji projektowej.

Zakres projektu obejmował przewidywanie pięciu list:

- pierwszej drużyny All-NBA,
- drugiej drużyny All-NBA,
- trzeciej drużyny All-NBA,
- pierwszej drużyny All-Rookie,
- drugiej drużyny All-Rookie.

3 Opis problemu

Problem przewidywania All-NBA można przedstawić jako klasyfikację wieloklasową z silną nierównowagą klas. Większość zawodników w danym sezonie nie otrzymuje żadnego wyróżnienia, natomiast tylko 15 zawodników trafia do jednej z trzech drużyn All-NBA. Klasy zostały zako-
dowane następująco:

Tabela 1: Kodowanie etykiet All-NBA.

Etykieta	Znaczenie
0	brak wyboru do All-NBA
1	trzecia drużyna All-NBA
2	druga drużyna All-NBA
3	pierwsza drużyna All-NBA

Analogicznie zdefiniowano etykiety dla All-Rookie:

Tabela 2: Kodowanie etykiet All-Rookie.

Etykieta	Znaczenie
0	brak wyboru do All-Rookie
1	druga drużyna All-Rookie
2	pierwsza drużyna All-Rookie

Ostateczny wynik modelu nie jest oceniany klasyczną dokładnością klasyfikacji. Punktacja zależy od tego, czy zawodnik został wybrany, czy trafił do poprawnej drużyny oraz ilu zawodników z danej drużyny zostało przewidzianych poprawnie.

4 Dane i przygotowanie zbioru

Dane wejściowe zostały zebrane automatycznie do katalogów `data/raw` oraz `data/static`. Głównym źródłem statystyk zawodników był pakiet `nba_api`, z którego pobierano dane sezonowe z punktu końcowego `LeagueDashPlayerStats`. Dla każdego sezonu pobierano kilka wariantów statystyk: `Base`, `Advanced`, `Misc`, `Usage`, `Scoring` oraz `Defense`. Dodatkowo pobierano statystyki z ostatnich 20 meczów sezonu dla wariantów `Base` i `Advanced`, a także osobny zbiór zawodników oznaczonych przez NBA jako debiutanci.

Etykiety nagród All-NBA i All-Rookie zostały pobrane z historycznych stron NBA. Dla każdej piątki przypisano wartość liczbową odpowiadającą pozycji drużyny: dla All-NBA wartości 3, 2 i 1 oznaczają odpowiednio pierwszą, drugą i trzecią drużynę, a dla All-Rookie wartości 2 i 1 oznaczają pierwszą oraz drugą drużynę. Brak wyboru do nagrody oznaczono jako 0.

Oprócz podstawowych statystyk przygotowano również pliki pomocnicze: sygnały reputacyjne, dane o głosowaniu All-NBA, zaawansowane metryki Basketball Reference oraz historię wyborów w drafcie. Dane te pozwalały testować różne warianty zbioru cech w ramach eksperymentów porównawczych. Wariant bazowy wykorzystywał jako cechy wejściowe przede wszystkim statystyki NBA, status debiutanta, cechy sumaryczne, cechy z poprzedniego sezonu oraz cechy względne względem drużyny. Etykiety nagród były używane jako zmienne docelowe podczas uczenia modeli.

W przypadku sygnałów reputacyjnych zastosowano niewielkie ręczne uzupełnienia danych źródłowych, m.in. dla listy All-Star 2026 oraz głosowania MVP 2025. Było to potrzebne, ponieważ najnowsze dane nie zawsze są dostępne w takim samym formacie jak sezony historyczne, a automatyczne parsowanie stron NBA może być niestabilne. Uzupełnienia te dotyczyły wyłącznie pomocniczych plików reputacyjnych używanych w eksperymentach i nie stanowiły ręcznej korekty końcowej predykcji. Ostateczny zestaw cech `previous_team_share` nie wykorzystuje tych sygnałów jako wejść modelu.

Tabela 3: Główne grupy danych przygotowane w projekcie.

Grupa danych	Pliki	Rola w projekcie
Statystyki z NBA API	<code>player_*_stats.csv</code> , <code>player_*_last20_stats.csv</code>	Główne dane wejściowe. Różne pliki to różne widoki <code>LeagueDashPlayerStats</code> : Base, Advanced, Misc, Usage, Scoring, Defense i last20.
Debiutanci z NBA API	<code>player_rookie_stats.csv</code>	Plik z filtrem <code>player_experience=Rookie</code> . Użyty do utworzenia flagi <code>IS_ROOKIE</code> .
Historia wyborów zawodników z NBA API	<code>draft_history.csv</code>	Dane o numerze wyboru zawodnika. Plik pomocniczy do eksperymentów z cechami dotyczącymi pozycji wyboru zawodnika.
Etykiety nagród	<code>all_nba_labels.csv</code> , <code>all_rookie_labels.csv</code>	Docelowe klasy modelu: wybór do All-NBA albo All-Rookie oraz numer drużyny.
Sygnały reputacyjne	<code>reputation_signals.csv</code>	Cechy o All-Star i głosowaniu MVP. Plik przygotowany do eksperymentów z dodatkowymi sygnałami reputacyjnymi.
Inne dane eksperymentalne	<code>all_nba_vote_share.csv</code> , <code>bref_player_advanced.csv</code>	Pliki testowane w eksperymentach. Udział w głosowaniu z tego samego sezonu nie był używany jako cecha, ponieważ zawiera wynik głosowania.
Pliki wynikowe projektu	<code>player_season_raw.csv</code> , <code>player_season_dataset.csv</code>	Połączone dane po wstępnym przetwarzaniu. Drugi plik jest ostatecznym zbiorem modelowym używanym do uczenia modeli oraz przygotowania przewidywań.

Ostateczny zbiór `player_season_dataset.csv` obejmuje sezony 2010–2026. Jedna obserwacja odpowiada jednemu zawodnikowi w jednym sezonie. Liczba pozytywnych przykładów jest niewielka w stosunku do całego zbioru, ponieważ w każdym sezonie tylko 15 zawodników trafia do All-NBA i 10 zawodników do All-Rookie.

Tabela 4: Podsumowanie ostatecznego zbioru danych.

Właściwość	Wartość
Liczba obserwacji	8783
Liczba kolumn	449
Zakres sezonów	2010–2026
Historyczne pozytywne etykiety All-NBA	240
Historyczne pozytywne etykiety All-Rookie	160
Liczba sezonów debiutanckich	1553

Proces budowania zbioru danych składał się z dwóch głównych etapów. Pierwszy etap, realizowany przez `collect_data.py`, odpowiadał za pobranie lub ponowne użycie plików źródłowych. Skrypt umożliwia wybór konkretnych grup danych przez parametr `-targets`, np. `stats`,

`awards`, `reputation`, `vote_share`, `bref_advanced` oraz `draft_history`. Domyślnie pobierany jest pełny zestaw danych.

Drugi etap, realizowany przez `build_dataset.py`, tworzy właściwy zbiór treningowy. Najpierw łączone są tabele statystyczne po kluczach `SEASON`, `PLAYER_ID` oraz `PLAYER_NAME`. Następnie dodawany jest znacznik debiutanta `IS_ROOKIE`, etykiety `All-NBA` i `All-Rookie`, cechy agregowane, cechy oparte na rangach, cechy względne względem drużyny oraz cechy z poprzedniego sezonu. Dodatkowe grupy cech były przygotowane osobno na potrzeby eksperymentów.

Do łączenia danych tekstowych zastosowano ujednolicony klucz `player_key`. Nazwy zawodników są normalizowane przez zamianę na małe litery, usunięcie znaków diakrytycznych, ujednolicenie apostrofów i redukcję spacji. Dodatkowo zastosowano awaryjny klucz dopasowania, który usuwa kropki, apostrofy oraz sufiksy typu `Jr`, `III` albo `IV`. Dzięki temu ograniczono problemy wynikające z różnych zapisów nazwisk w kilku źródłach.

5 Inżynieria cech

W projekcie przygotowano kilka grup cech, jednak ostateczny wariant przewidywania oparto na zestawie cech `previous_team_share`. Oznacza to, że model wykorzystywał statystyki podstawowe i zaawansowane z NBA API, cechy sumaryczne, cechy z poprzedniego sezonu oraz cechy opisujące rolę zawodnika w drużynie. Szersze zestawy cech, m.in. cechy reputacyjne, cechy dotyczące pozycji wyboru zawodnika, cechy oparte na rangach, cechy dotyczące ostatnich meczów oraz metryki Basketball Reference, były przygotowane i testowane w ramach eksperymentów porównawczych.

5.1 Cechy podstawowe

Do podstawowych cech należały standardowe statystyki sezonowe zawodnika: wiek, liczba rozegranych meczów, minuty, punkty, zbiórki, asysty, przechwyty, bloki, straty, skuteczność rzutowa oraz podstawowe statystyki drużynowe, takie jak liczba zwycięstw i procent zwycięstw. Wykorzystano również statystyki zaawansowane dostępne przez NBA API, m.in. rating ofensywny, rating defensywny, rating netto, wskaźnik użycia, wskaźnik `TS%` oraz `PIE`.

Cechy te stanowiły główny opis aktualnej formy zawodnika w danym sezonie. Nie ograniczono się wyłącznie do prostych statystyk meczowych, ponieważ wybory do `All-NBA` i `All-Rookie` zależą również od efektywności, roli w zespole oraz jakości drużyny.

5.2 Cechy sumaryczne

Ponieważ głosowanie często uwzględnia nie tylko średnie na mecz, ale również łączną produkcję w sezonie, dodano cechy sumaryczne:

- $TOTAL_MIN = GP * MIN$,
- $TOTAL_PTS = GP * PTS$,
- $TOTAL_REB = GP * REB$,
- $TOTAL_AST = GP * AST$,
- $PTS_REB_AST = PTS + REB + AST$,
- $STOCKS = STL + BLK$,
- $AST_TOV_SIMPLE = AST / (TOV + 0.1)$.

Cechy sumaryczne były ważne szczególnie dlatego, że zawodnik z wysokimi średnimi, ale małą liczbą rozegranych meczów, może mieć słabszy profil kandydatury niż zawodnik o podobnej efektywności i większej dostępności w sezonie.

5.3 Cechy z poprzedniego sezonu

Do ostatecznego zestawu dodano cechy z poprzedniego sezonu, m.in. poprzednią liczbę punktów, zbiórek, asyst, przechwyty, bloków, rozegranych meczów, minut, procent zwycięstw drużyny, wskaźnik TS%, wskaźnik użycia oraz PIE. Uwzględniono również poprzednią etykietę All-NBA.

Cechy historyczne pozwalają modelowi uwzględnić ciągłość kariery zawodnika i jego pozycję w lidze bez korzystania z informacji z przyszłości. Wszystkie te wartości są przesunięte względem sezonu, dla którego wykonywano przewidywanie, dlatego mogą być używane w scenariuszu walidacji kroczącej.

5.4 Cechy drużynowe i względne względem drużyny

W głosowaniu All-NBA duże znaczenie ma nie tylko poziom indywidualny zawodnika, ale również kontekst drużyny. Dlatego w ostatecznym zestawie `previous_team_share` wykorzystano cechy opisujące pozycję zawodnika w jego zespole oraz jakość drużyny w skali ligi.

Do tej grupy należały m.in. rangi zawodnika w drużynie według łącznej liczby punktów, asyst i minut, udział zawodnika w punktach, asystach i minutach drużyny, wskaźniki lidera drużyny oraz ranking drużyny w lidze według procentu zwycięstw i ratingu netto. Dzięki temu model mógł odróżniać zawodników o podobnych statystykach indywidualnych, ale pełniących inną rolę w zespole albo grających w drużynach o różnym poziomie sukcesu.

5.5 Cechy przygotowane do eksperymentów

Oprócz cech użytych w ostatecznym wariancie przygotowano również dodatkowe grupy cech. Obejmowały one m.in. percentylowe rangi zawodników w ramach sezonu, statystyki z ostatnich 20 meczów sezonu, sygnały reputacyjne, dane o pozycji wyboru zawodnika, metryki Basketball Reference oraz dane o głosowaniu All-NBA.

Cechy reputacyjne obejmowały m.in. wybór do All-Star, wcześniejsze nominacje All-NBA oraz wcześniejszy udział w głosowaniu MVP. Cechy dotyczące pozycji wyboru zawodnika obejmowały m.in. numer wyboru zawodnika, rundę wyboru, oznaczenia wyboru w pierwszej trójce, wyboru w pierwszej piątce, wyboru loteryjnego oraz wyboru w pierwszej rundzie. Te grupy danych były wykorzystywane w eksperymentach porównawczych, ale nie weszły do ostatecznego zestawu cech `previous_team_share`.

6 Metodyka eksperymentów

Eksperymenty prowadzono metodą walidacji kroczącej. Dla każdego sezonu testowego model był trenowany wyłącznie na sezonach wcześniejszych. Przykładowo, przy przewidywaniu sezonu 2025 model mógł korzystać z danych do sezonu 2024 włącznie. Takie podejście ogranicza ryzyko przecieku informacji z przyszłości i odpowiada rzeczywistemu scenariuszowi użycia modelu, w którym skład nagród dla nowego sezonu przewiduje się na podstawie danych historycznych.

Wszystkie warianty oceniano zgodnie z punktacją projektową, a nie za pomocą klasycznej dokładności klasyfikacji. Oceniany był końcowy plik z przewidywaniami, czyli trzy drużyny All-NBA oraz dwie drużyny All-Rookie. Wynik zależał od poprawnego wyboru zawodników, poprawnego przypisania ich do drużyn oraz premii za większą liczbę trafień w obrębie jednej drużyny.


6.1 Dobór modeli pierwszego etapu

Pierwszym krokiem było sprawdzenie, który model najlepiej nadaje się do wstępnego wyboru kandydatów. Porównano kilka wariantów: `ExtraTrees`, `ExtraTrees balanced`, `RandomForest`, `RandomForest balanced`, `HGB classifier` oraz `HGB regressor`. Testy przeprowadzono osobno dla All-NBA oraz All-Rookie, ponieważ oba zadania mają inną strukturę.

Dla All-NBA najlepszy średni wynik w ostatnich 10 sezonach uzyskał model **RandomForest**. Wyniki porównania przedstawiono w tabeli 5. Na tej podstawie w części All-NBA jako model pierwszego etapu wybrano **RandomForest**.

Tabela 5: Porównanie modeli pierwszego etapu dla All-NBA.

Model	Średni wynik	Procent maksimum
RandomForest	140.7 / 270	52.11%
ExtraTrees	139.6 / 270	51.70%
HGB classifier	136.0 / 270	50.37%
RandomForest balanced	133.6 / 270	49.48%
ExtraTrees balanced	131.4 / 270	48.67%
HGB regressor	128.5 / 270	47.59%




Rysunek 1: Porównanie modeli pierwszego etapu dla All-NBA w sezonach 2016–2025.

Dla All-Rookie sytuacja była inna. Najlepszy średni wynik uzyskał **HGB classifier**. Wyniki porównania przedstawiono w tabeli 6. Dlatego dla All-Rookie wybrano prostszy wariant oparty na **HGB classifier**.


Tabela 6: Porównanie modeli pierwszego etapu dla All-Rookie.

Model	Średni wynik	Procent maksimum
HGB classifier	125.7 / 180	69.83%
RandomForest	119.4 / 180	66.33%
ExtraTrees balanced	115.8 / 180	64.33%
RandomForest balanced	113.0 / 180	62.78%
ExtraTrees	112.3 / 180	62.39%
HGB regressor	109.3 / 180	60.72%



Rysunek 2: Porównanie modeli pierwszego etapu dla All-Rookie w sezonach 2016–2025.

Wyniki łączne także pokazały, że nie ma jednego modelu, który byłby najlepszy dla obu części zadania. Najlepszy wynik łączny w samym pierwszym etapie uzyskał **HGB classifier** z wynikiem 261.7 punktu, a drugi był **RandomForest** z wynikiem 260.1 punktu. Jednak analiza osobna dla All-NBA i All-Rookie pokazała, że korzystniejsze jest użycie różnych modeli dla różnych części zadania: **RandomForest** dla All-NBA oraz **HGB classifier** dla All-Rookie.




Rysunek 3: Średni wynik łączny dla wariantów pierwszego i drugiego etapu.

6.2 Analiza drugiego etapu

Po wyborze modeli pierwszego etapu sprawdzono, czy dodatkowy etap porządkowania kandydatów poprawia wynik. W All-NBA problem polega nie tylko na wskazaniu 15 najlepszych kandydatów, ale również na przypisaniu ich do pierwszej, drugiej i trzeciej drużyny. Z tego powodu przetestowano kilka wariantów drugiego etapu: klasyfikator, regresor oraz podejście `slot_binary_ml`.


W prostym uśrednieniu najlepszy wynik All-NBA osiągnął wariant jednoetapowy, czyli `Stage1 only`, z wynikiem 140.7 punktu. Wariant `Stage1 + stage2 classifier` uzyskał 136.1 punktu, `Stage1 + slot_binary_ml` 134.7 punktu, a `Stage1 + stage2 regressor` 134.4 punktu. Sam wynik średni nie był więc wystarczającym argumentem za drugim etapem. Drugi etap pozostawiono jednak w części All-NBA jako mechanizm jawnie modelujący przypisanie zawodników do konkretnych drużyn. Było to istotne, ponieważ końcowa metryka nagradza nie tylko obecność zawodnika w top 15, ale również poprawne miejsce w strukturze trzech drużyn.




Rysunek 4: Porównanie wariantów drugiego etapu dla All-NBA w sezonach 2016–2025.

Ostatecznie dla All-NBA zastosowano architekturę `RandomForest + slot_binary_ml`. Decyzja ta wynikała z chęci uzyskania bardziej kontrolowanego przypisania zawodników do drużyn, zamiast polegania wyłącznie na jednym uporządkowaniu kandydatów. Szczególnie sezon 2024 pokazał duży skok wyniku dla części modeli, dlatego nie opierano wyboru finalnej architektury wyłącznie na założeniu, że podobny skok powtórzy się w sezonie 2026.

Dla All-Rookie przeprowadzono analogiczną analizę drugiego etapu, ale wyniki nie uzasadniły jego użycia w finalnym rozwiązaniu. Najlepszy wariant z dodatkowym etapem osiągnął 122.9 punktu, natomiast najlepszy jednoetapowy model dla All-Rookie, czyli `HGB classifier`, osiągnął 125.7 punktu. Oznacza to, że drugi etap nie poprawił jakości predykcji debutantów i mógł niepotrzebnie zwiększać złożoność modelu. Dlatego w finalnym rozwiązaniu dla All-Rookie pozostawiono wariant jednoetapowy.



Rysunek 5: Porównanie wariantów drugiego etapu dla All-Rookie w sezonach 2016–2025.




Rysunek 6: Średni wynik wariantów drugiego etapu dla All-Rookie.

6.3 Porównanie zestawów cech

Kolejnym etapem było porównanie różnych zestawów cech. Jako punkt odniesienia traktowano wariant `previous_team_share`, który zawiera statystyki podstawowe i zaawansowane, cechy sumaryczne, cechy z poprzedniego sezonu oraz cechy opisujące rolę zawodnika w drużynie.

Testowano również warianty rozszerzone o sygnały reputacyjne, dane o pozycji wyboru zawodnika w drafcie, wcześniejsze głosowania oraz dodatkowe źródła statystyk. Wykres pokazuje,


że rozszerzanie zbioru cech nie prowadziło do jednoznacznej i stabilnej poprawy. W niektórych sezonach warianty rozszerzone wypadały lepiej, ale nie dawały przewagi wystarczająco stabilnej, aby uznać je za bezpieczniejszy wybór dla sezonu 2026.



Rysunek 7: Porównanie pięciu najlepszych zestawów cech w sezonach 2016–2025.

Osobno porównano wariant bazowy z wariantem wykorzystującym cechy reputacyjne. Cechy reputacyjne obejmowały m.in. wybór do All-Star, wcześniejsze wybory do All-NBA oraz wcześniejszy udział w głosowaniu MVP. Taki zestaw cech był teoretycznie uzasadniony, ponieważ głosowania medialne często uwzględniają rozpoznawalność zawodnika i jego wcześniejszą pozycję w lidze. W praktyce jednak model z tymi cechami nie był wystarczająco stabilny. Dodatkowo cechy reputacyjne mogły wzmacniać zawodników z dłuższą historią nagród kosztem młodych zawodników, którzy już osiągnęli bardzo wysoki poziom sportowy, ale nie mieli jeszcze długiej historii wyróżnień. Przykładem takiego problemu był Victor Wembanyama. Z tego powodu w finalnym rozwiązaniu zrezygnowano z cech reputacyjnych.

Sprawdzono również wariant oparty na zespole kilku modeli. Zakładano, że połączenie wyników różnych klasyfikatorów może zmniejszyć wpływ pojedynczych błędów i poprawić stabilność przewidywań. W praktyce modele pierwszego etapu dawały jednak dość zbliżone listy kandydatów, dlatego ich połączenie nie wniosło nowej informacji wystarczającej do poprawy końcowego wyniku. Z tego powodu w finalnym rozwiązaniu pozostawiono pojedyncze modele dobrane osobno dla All-NBA i All-Rookie.



Rysunek 8: Porównanie wariantu bazowego i wariantu z cechami reputacyjnymi.

Sprawdzono również wariant z większym zakresem sezonów, rozpoczynającym się od sezonu 2000. Ten eksperyment nie przyniósł poprawy końcowego wyniku. Możliwym wyjaśnieniem jest zmiana charakteru ligi oraz sposobu wybierania drużyn All-NBA. W starszych sezonach większe znaczenie miały pozycje zawodników, natomiast w nowszych sezonach All-NBA jest wybierane bez sztywnego podziału pozycyjnego. Z tego powodu zbyt stare dane mogły wprowadzać dodatkowy szum zamiast poprawiać uogólnienie modelu.

Analogicznie sprawdzono wariant wykorzystujący dodatkowe dane Basketball Reference. Metryki takie jak zaawansowane wskaźniki efektywności były potencjalnie wartościowe, ale w przeprowadzonych eksperymentach nie poprawiły stabilnie wyniku końcowego. Możliwe, że część informacji niesionej przez te dane była już pośrednio obecna w statystykach z NBA API, takich jak TS_PCT, USG_PCT, PIE, rating ofensywny, rating defensywny oraz rating netto.

6.4 Zakres danych użytych w projekcie

Chociaż finalny model korzysta tylko z wybranego zestawu cech `previous_team_share`, w projekcie zachowano szerszy proces budowania zbioru danych. Od sezonu 2010 pobierane są statystyki `Base`, `Advanced`, `Misc`, `Usage`, `Scoring`, `Defense`, statystyki z ostatnich 20 meczów dla `Base` i `Advanced`, dane debiutantów, etykiety All-NBA i All-Rookie, sygnały reputacyjne, dane o głosowaniu All-NBA, metryki Basketball Reference oraz historia draftu.

Nie wszystkie te dane są bezpośrednio używane w finalnym modelu. Część z nich była potrzebna do eksperymentów porównawczych, a część pozwalała sprawdzić, czy szerszy opis zawodnika poprawia wynik. W praktyce pozostawienie pełnego procesu przygotowania danych od 2010 roku było korzystniejsze niż ograniczenie projektu tylko do minimalnych plików odpowiadających finalnym cechom. Wariant oparty na zbyt wąskim zbiorze danych dawał niższy średni wynik, dlatego finalny projekt zachowuje pełniejszy proces przygotowania danych, mimo że końcowy model wybiera tylko określone kolumny wejściowe.

6.5 Architektura finalnego modelu

Finalny model składa się z dwóch niezależnych części: jednej dla All-NBA i jednej dla All-Rookie.

W części All-NBA zastosowano model dwuetapowy. W pierwszym etapie model `RandomForestClassifier` oblicza prawdopodobieństwa przynależności zawodnika do pierwszej, drugiej i trzeciej drużyny All-NBA. Na tej podstawie obliczany jest wynik rankingowy:

$$score_{AllNBA} = 3 \cdot P(first) + 2 \cdot P(second) + 1 \cdot P(third). \quad (1)$$

Następnie zawodnicy są sortowani według tego wyniku i tworzona jest pula 30 kandydatów. Dla sezonów objętych zasadą minimalnej liczby rozegranych meczów stosowany jest również filtr kwalifikowalności. W sezonie 2026 uwzględniono wyjątki dla zawodników, którzy w danych projektowych powinni pozostać kwalifikowalni mimo niespełnienia prostego warunku liczby meczów.

W drugim etapie All-NBA używany jest wariant `slot_binary_ml`. Dla każdej z trzech drużyn trenowany jest osobny model binarny. Najpierw model wybiera pięciu zawodników najbardziej pasujących do pierwszej drużyny. Następnie wybrani zawodnicy są usuwani z puli, a kolejny model wybiera pięciu zawodników do drugiej drużyny. Na końcu trzeci model wybiera pięciu zawodników do trzeciej drużyny. Dzięki temu etap drugiego poziomu nie tylko porządkuje kandydatów, ale bezpośrednio modeluje przypisanie do konkretnych drużyn.

W części All-Rookie zastosowano prostszy wariant jednoetapowy. Model `HGB classifier` trenowany jest wyłącznie na zawodnikach oznaczonych jako debiutanci. Dla każdego debiutanta obliczane są prawdopodobieństwa przynależności do pierwszej i drugiej drużyny All-Rookie, a następnie wynik:

$$score_{Rookie} = 2 \cdot P(first\ rookie) + 1 \cdot P(second\ rookie). \quad (2)$$

Po posortowaniu kandydatów według tego wyniku wybieranych jest 10 zawodników. Pierwszych pięciu trafia do pierwszej drużyny All-Rookie, a kolejnych pięciu do drugiej drużyny. Dodatkowy etap porządkowania dla All-Rookie nie został użyty, ponieważ w testach nie poprawiał stabilnie wyniku, a najlepszy jednoetapowy `HGB classifier` uzyskał wyższy średni rezultat niż warianty dwuetapowe.

Ostatecznie finalna konfiguracja projektu jest następująca:

- zestaw cech: `previous_team_share`,
- All-NBA: `RandomForestClassifier` jako pierwszy etap oraz `slot_binary_ml` jako drugi etap,
- All-Rookie: jednoetapowy `HGB classifier`,
- zakres walidacji porównawczej: sezony 2016–2025,
- sezon przewidywany w finalnym pliku: 2026.

7 Wynik końcowy

Aby podsumować wybór konfiguracji, w tabeli przedstawiono średni wynik finalnego wariantu w walidacji kroczącej dla sezonów 2016–2025, osobno dla części All-NBA i All-Rookie oraz łącznie.

Tabela 7: Średni wynik finalnego wariantu w sezonach 2016–2025.

Część modelu	Średni wynik	Procent maksimum
All-NBA: <code>RandomForest</code> + <code>slot_binary_ml</code>	134.7 / 270	49.89%
All-Rookie: <code>HGB classifier</code>	125.7 / 180	69.83%
Łącznie	260.4 / 450	57.87%

Wygenerowana predykcja dla sezonu 2026 ma następującą postać:

Tabela 8: Predykcja All-NBA dla sezonu 2026.

Drużyna	Zawodnicy
Pierwsza drużyna All-NBA	Nikola Jokić, Luka Dončić, Shai Gilgeous-Alexander, Victor Wembanyama, Chet Holmgren
Druga drużyna All-NBA	Jaylen Brown, Donovan Mitchell, Kevin Durant, Kawhi Leonard, Jamal Murray
Trzecia drużyna All-NBA	Karl-Anthony Towns, Cade Cunningham, Tyrese Maxey, Jalen Johnson, Jalen Brunson

Tabela 9: Predykcja All-Rookie dla sezonu 2026.

Drużyna	Zawodnicy
Pierwsza drużyna All-Rookie	Cooper Flagg, VJ Edgecombe, Kon Knueppel, Derik Queen, Cedric Coward
Druga drużyna All-Rookie	Maxime Raynaud, Jeremiah Fears, Dylan Harper, Ace Bailey, Collin Murray-Boyles

8 Analiza błędów i ograniczenia

Najtrudniejsze przypadki dotyczą zawodników znajdujących się na granicy wyboru do All-NBA albo na granicy drugiej i trzeciej drużyny. W takich sytuacjach różnice statystyczne między kandydatami są niewielkie, a ostateczne głosowanie może zależeć od czynników trudnych do opisania liczbowo, takich jak narracja medialna, oczekiwania wobec zawodnika czy sposób postrzegania sukcesu drużyny.

W przypadku All-NBA dodatkowym problemem jest przypisanie zawodników do konkretnej drużyny. Model pierwszego etapu dobrze identyfikuje szeroką grupę kandydatów, ale sama globalna kolejność nie zawsze odpowiada strukturze trzech pięcioosobowych drużyn. Z tego powodu w finalnym rozwiązaniu zastosowano drugi etap oparty na modelach binarnych dla kolejnych drużyn.

Dla All-Rookie głównym ograniczeniem jest mniejsza liczba kandydatów i mniejsza liczba historycznych przykładów. Debiutanci często mają niestabilne role w drużynach, a ich pozycja może zależeć od minut gry, kontuzji innych zawodników albo decyzji trenerskich. W tym przypadku prostszy model jednoetapowy okazał się stabilniejszy niż dodatkowe modele porządkujące.

W eksperymentach analizowano również cechy reputacyjne, dane z Basketball Reference oraz dane o głosowaniu. Nie zostały one użyte w finalnym wariancie, ponieważ nie dawały wystarczająco stabilnej poprawy. Cechy reputacyjne mogły dodatkowo wzmacniać zawodników z dłuższą historią wyróżnień kosztem młodych graczy, którzy dopiero budują swoją pozycję w lidze.

9 Instrukcja uruchomienia

Projekt można uruchomić z poziomu katalogu głównego repozytorium. Dane wejściowe znajdują się w katalogach `data/raw` oraz `data/static`, a gotowy zbiór modelowy znajduje się w pliku `data/processed/player_season_dataset.csv`.

W przypadku konieczności ponownego pobrania danych źródłowych należy uruchomić:

```
1 python src/collect_data.py
```

Listing 1: Pobieranie danych źródłowych.

Po pobraniu danych albo przy użyciu już przygotowanych plików źródłowych można zbudować zbiór modelowy:

```
1 python src/build_dataset.py
```

Listing 2: Budowanie zbioru modelowego.

Uczenie finalnego modelu dla sezonu 2026 wykonywane jest poleceniem:

```
1 python src/train.py
```

Listing 3: Uczenie finalnego modelu.

Polecenie zapisuje wytrenowany model do pliku `models/final_pipeline.joblib`. Następnie przewidywanie można wygenerować poleceniem:

```
1 python src/predict.py
```

Listing 4: Generowanie finalnego przewidywania.

10 Wnioski

Projekt pokazał, że przewidywanie składów All-NBA i All-Rookie wymaga osobnego podejścia do obu zadań. Dla All-NBA najlepsze okazało się połączenie modelu dobrze wybierającego szeroką pulę kandydatów z dodatkowym etapem przypisania zawodników do drużyn. Dla All-Rookie stabilniejsze było prostsze rozwiązanie jednoetapowe.

Eksperymenty pokazały również, że dodawanie kolejnych źródeł danych nie zawsze poprawia wynik. Szersze zestawy cech, obejmujące m.in. sygnały reputacyjne, dane o pozycji wyboru zawodnika oraz metryki Basketball Reference, nie dawały wystarczająco stabilnej przewagi nad zestawem `previous_team_share`. Dlatego finalny wariant pozostawiono prostszy i bardziej przewidywalny.

Najważniejszym ograniczeniem modelu pozostaje rozróżnianie zawodników o bardzo podobnym poziomie sportowym, szczególnie na granicy drugiej i trzeciej drużyny All-NBA oraz na granicy wyboru do pierwszej piętnastki. Są to przypadki, w których nawet niewielkie różnice w głosowaniu mogą prowadzić do innego końcowego układu drużyn.